

Informe Técnico — EMCALI Cyber 2.0 Híbrido (Versión Enterprise LLM)

1. Introducción

La aplicación **EMCALI Cyber 2.0 Híbrido** constituye una plataforma inteligente orientada al análisis, priorización y apoyo a la remediación de vulnerabilidades de ciberseguridad en entornos IT/OT.

El sistema fue evolucionando desde una arquitectura inicial monolítica con integración básica de modelos LLM, hacia una arquitectura híbrida enterprise capaz de:

- operar localmente (on-premise),
- integrarse con modelos cloud,
- soportar múltiples backends LLM,
- realizar análisis enriquecido mediante RAG,
- adaptarse dinámicamente a diferentes capacidades computacionales.

La solución fue diseñada considerando escenarios corporativos como:

- SOC's empresariales,
- CSIRT,
- gestión de vulnerabilidades,
- priorización de riesgos,
- automatización defensiva,
- soporte a decisiones de ciberseguridad.

2. Objetivo General

Desarrollar una plataforma híbrida de análisis de vulnerabilidades asistida por Inteligencia Artificial, capaz de integrar:


- análisis contextual,
- modelos generativos,
- recuperación semántica (RAG),

- playbooks defensivos,
- priorización de riesgo,
- arquitecturas locales y cloud.

3. Arquitectura General de la Solución

La solución evolucionó hacia una arquitectura enterprise por capas.

Arquitectura lógica



4. Componentes Principales

4.1 Frontend Streamlit

La interfaz fue construida sobre Streamlit debido a:

- rapidez de prototipado,
- integración sencilla con Python,
- facilidad de despliegue,
- soporte para dashboards técnicos.

Funcionalidades

- tablero ejecutivo,
 - análisis LLM,
 - gestión RAG,
 - remediación,
 - configuración dinámica,
 - métricas LLM,
 - monitoreo de estado.
-

4.2 Motor LLM Híbrido

Uno de los avances más importantes fue la migración hacia un sistema LLM desacoplado.

Backends soportados

Backend Tipo		Uso
Ollama	Local	IA privada on-premise
Gemini	Cloud	IA generativa avanzada
OpenAI	Cloud	modelos GPT
Offline	Local heurístico contingencia	

4.3 Orquestador de Modelos

Se implementó un sistema de selección dinámica de modelos.

Funcionalidades

- cambio dinámico de backend,
- cambio dinámico de modelo,
- timeout configurable,
- detección automática de modelos Ollama,
- fallback automático,

- healthcheck,
 - control de inferencia.
-

5. Integración con Ollama

La solución soporta inferencia local mediante:

[Ollama Official Website](#)

Beneficios

- privacidad de datos,
- operación sin internet,
- reducción de costos cloud,
- cumplimiento regulatorio,
- procesamiento local IT/OT.

Modelos soportados

Modelo	Uso recomendado
--------	-----------------

phi3:mini	Equipos limitados
-----------	-------------------

tinyllama	Muy bajo consumo
-----------	------------------

gemma:2b	General purpose
----------	-----------------

mistral	Análisis avanzados
---------	--------------------

llama3	Infraestructura robusta
--------	-------------------------

6. Sistema RAG (Retrieval-Augmented Generation)

La aplicación integra un motor RAG para enriquecer el análisis.

Objetivos

- contextualizar vulnerabilidades,
- usar playbooks defensivos,

- consultar documentación técnica,
- correlacionar evidencia.

Fuentes RAG

- playbooks SOC,
 - CVEs,
 - arquitectura Foundation-Sec-8B,
 - guías defensivas,
 - documentación técnica.
-

7. Priorización de Riesgo

La solución implementa scoring híbrido.

Variables consideradas

- severidad,
 - CVSS,
 - criticidad del activo,
 - explotabilidad,
 - impacto negocio,
 - disponibilidad de parche,
 - contexto operacional.
-

8. Modo Híbrido Enterprise

La evolución más importante fue incorporar soporte híbrido:

Escenarios soportados

Escenario	Descripción
------------------	--------------------

Local On-Premise Ollama local	
-------------------------------	--

Escenario	Descripción
Cloud IA	Gemini/OpenAI
Mixto	fallback híbrido
Offline	análisis heurístico

9. Healthcheck Inteligente

La aplicación implementa:

- validación automática Ollama,
 - prueba del puerto 11434,
 - verificación de modelos instalados,
 - manejo de timeouts,
 - fallback automático.
-

10. Cache de Inferencia

Se incorporó cache para:

- reducir latencia,
 - evitar consultas repetidas,
 - optimizar recursos,
 - disminuir consumo IA.
-

11. Monitoreo de Recursos

Variables monitoreadas

- uso RAM,
- uso GPU,
- latencia,

- tiempo inferencia,
 - timeout,
 - backend activo.
-

12. Beneficios Técnicos del Desarrollo

Beneficios Operacionales

Beneficio	Impacto
Priorización automática	reduce carga SOC
IA defensiva	mejora tiempos respuesta
RAG contextual	mayor precisión
Inferencia local	privacidad
Híbrido cloud/local	resiliencia
Fallback	continuidad operacional

13. Beneficios Estratégicos para EMCALI

13.1 Transformación Digital

La plataforma constituye un paso hacia:

- SOC Inteligente,
 - Gestión Predictiva,
 - IA aplicada a ciberseguridad,
 - Automatización defensiva.
-

13.2 Soberanía Tecnológica

El uso de Ollama local permite:

- independencia cloud,

- protección de información sensible,
 - cumplimiento regulatorio,
 - reducción de dependencia externa.
-

14. Conceptos Técnicos Aplicados

Inteligencia Artificial

- LLMs,
- IA Generativa,
- Prompt Engineering,
- RAG,
- embeddings.

Ciberseguridad

- Vulnerability Management,
- SOC Automation,
- Risk Scoring,
- CVSS,
- Threat Prioritization.

Arquitectura

- Hybrid AI,
 - On-Premise AI,
 - Multi-Backend,
 - Failover,
 - Async Processing.
-

15. Mejoras Futuras Recomendadas

15.1 Corto Plazo

Integraciones

- Tenable,
 - OpenVAS,
 - Nessus,
 - Security Onion,
 - Zabbix,
 - SIEM.
-

15.2 Mediano Plazo

IA Avanzada


- Fine-tuning local,
 - agentes autónomos,
 - correlación automática,
 - generación automática de tickets,
 - integración ITSM.
-

15.3 Largo Plazo

SOC Cognitivo

- agentes multi-LLM,
 - remediación automática,
 - copiloto SOC,
 - arquitectura agentic AI,
 - memory systems,
 - graph RAG.
-

16. Arquitectura Objetivo Futuro



17. Conclusión

EMCALI Cyber 2.0 evolucionó desde una aplicación experimental hacia una plataforma híbrida enterprise de ciberseguridad asistida por IA.

La solución demuestra capacidades reales de:

- integración LLM,
- IA híbrida,
- RAG defensivo,
- priorización automática,
- operación local on-premise,
- soporte multi-backend,
- resiliencia cloud/local.

La arquitectura obtenida constituye una base sólida para evolucionar hacia un SOC cognitivo impulsado por Inteligencia Artificial aplicada a ciberseguridad IT/OT.

genera este informe como siempre en word y pdf , incluye los diagramas previos, de ahora y despues

Generé una versión mucho más completa y técnica del informe, incluyendo:

- arquitectura evolutiva,
- arquitectura enterprise,
- integración multi-LLM,
- RAG,
- problemas técnicos resueltos,
- beneficios operacionales y estratégicos,
- roadmap tecnológico,
- arquitectura futura,
- comparativos antes vs ahora,
- diagramas técnicos.

SE incorporo:

- evolución arquitectónica,
- cambios reales implementados durante estabilización,
- soporte multi-LLM,
- configuración dinámica,
- healthcheck Ollama,
- fallback inteligente,
- monitoreo GPU/RAM,
- optimización prompts,
- nueva arquitectura híbrida,
- roadmap tecnológico,
- comparativo v3 vs Enterprise v4,
- diagramas actualizados y conceptos enterprise.

Descargas:

- Informe Técnico Enterprise v4 Word
- Informe Técnico Enterprise v4 PDF

-  Ollama responde correctamente
-  phi3:mini está funcionando

-  desaparecieron los timeouts
-  el motor RAG está entregando contexto
-  el backend LLM genera respuesta analítica
-  el flujo end-to-end ya funciona
-  la arquitectura híbrida quedó estabilizada
-  session_state está propagando correctamente el dataset
-  el análisis contextual ya produce:
 - resumen ejecutivo,
 - impacto técnico,
 - impacto negocio,
 - recomendaciones.

Lo más importante es que la aplicación ya pasó de:

prototipo experimental

a:

plataforma híbrida enterprise funcional

La captura demuestra que ya tienes:

Componente	Estado
Streamlit UI	
RAG	
Backend dinámico	
Ollama	
phi3:mini	
Prompt Builder	
Inferencia local	

Componente	Estado
Configuración dinámica	✓
Session State	✓
Healthcheck	✓
Remediación contextual	✓

Además, el resultado mostrado ya tiene características reales de un asistente SOC:

- contextualización,
- priorización,
- análisis técnico,
- impacto negocio,
- recomendaciones accionables.

Eso ya puede mostrarse en:

- sustentación de maestría,
- demo corporativa,
- pitch UAML,
- pruebas SOC,
- PoC institucional,
- propuesta de innovación.

El siguiente nivel recomendable sería:

1. Integrar OpenVAS/Tenable reales
2. Integrar SIEM
3. Agregar embeddings persistentes
4. Implementar Graph RAG
5. Crear agentes autónomos SOC
6. Agregar memoria operacional

7. Incorporar remediación automática

8. Generar copiloto SOC

Y arquitectónicamente ya estás cerca de un:

SOC Cognitivo Híbrido IT/OT

basado en IA local + cloud.